

基于深度学习的社区检测综合研究

2022.11.10

摘要: 在网络中检测一个社区，是为了识别一组不同于其他社区的成员的不同特征和联系。这一能力在网络分析中具有很重要的作用。除了统计推断等传统方法外，近年来深度学习技术在社区检测应用中有了很好的发展，特别是在处理高维数据时。本文基于 CNN 算法和自动编码器在社区检测中的融合，介绍了社区检测在深度学习的状态。也对社区检测的发展前景做出了展望。

关键词: 深度学习 社区检测 CNN 算法 自动编码器

Abstract: Detecting a community in a network is a matter of discerning the distinct features and connections of a group of members that are different from those in other communities. The ability to do this is of great significance in network analysis. In addition to traditional methods such as statistical inference, deep learning techniques have developed well in community detection applications in recent years, especially when processing high-dimensional data. Based on the fusion of CNN algorithm and auto-encoder in community detection, this paper introduces the state of community detection in deep learning. The development prospect of community detection is also forecast.


Key words: Deep learning Community detection CNN algorithm Auto-encoder

1. 社区检测的概况与发展

1.1 社区检测的介绍

1.1.1 社区的定义

我们可以将网络理解为一个表示关系的集合，而“社区”在这篇文献中并没有一种严格的定义，我们可以理解为一类具有相同特性的节点的集合，由一群紧密相连的网络节点组成。如图1，同一个社区内的节点联系紧密，不同社区的节点连接稀疏。



图一：社区

定义一个节点是否在某个社区之中的方法，就是看该节点与该社区中的其他节点的关联是否密切。或者说，正是这一簇互相关联紧密的节点，才构造出了网络中的一个社区。事实上，我们的世界就是一个由一系列社区组成的庞大网络。

在现实问题的网络中，社区划分往往会形成一组社区，我们可以表示为 $C = \{C_1, C_2, \dots, C_K\}$ ，每个社区 C_k 都是 C 的分区，均具有独特的区域结构和集群属性。如果存在：

$$C_k \cap C_{k'} = \emptyset \quad (\forall k, k', k \neq k')$$

则将 C 定义为脱节的社区，反之为重叠的社区。

1.1.2 社区检测的定义

在网络中进行检测社区就是要识别一组成员的不同特征和联系，并通过特定的检测方法，判断一个节点是否属于某个社区，以及有多少个社区，将网络中联系紧密的部分（即社区）找出来，进而将结果输出为一组脱节或重叠的社区，因此社区检测揭示了网络聚集行为，类似于一种网络聚类的方法。

脱节和重叠的社区在我们现实生活中有很多例子。比如将一所大学里面的每个同学都看作一个节点并组成网络，如果按照班级进行社区划分，每位同学只会属于一个班级，每个班级作为一个独立的社区，社区之间没有相同的节点，因此就会输出脱节的社区；在每一学期，每位同学会选择多门课程进行学习，如果按照课程进行社区划分，即选择了同一门课程的同学的集合作为一个社区，同学个体作为一个节点，会同时处在不同社区中，进而就会产生重叠的社区。

1.1.3 社区检测的作用

社区检测可以拉近节点之间的距离。以 1.1.2 中的例子为例，在大学校园里，对于两个完全陌生的同学，他们之间相遇认识的概率比较渺茫，而某一时期他们同时处于一个或多个社区，即在同一学期选择了一门或者多门相同课程时，他们之间的相同特征就会增加如相同话题、学习目标等，从他们之间联系就会增加，并有更大几率成为好朋友，即节点之间的距离会被拉近。

以蛋白质相互关系网络为例，我们可以将参加同一类生命活动的蛋白质定义为一个社团，我们可以通过跟踪观察所研究的蛋白质出现在哪些社团之中，来分析该蛋白质的作用，甚至可以以此为基础来预测新型蛋白质的作用。

在互联网上，社团检测的应用领域也非常广泛。例如搜索引擎，可以对用户搜索的关键词进行社团检测，找出其中的“热门领域”，进而增加这方面信息的检索。

社区检测用处远不止于此，在当今社会非常广泛，可用于详细跟踪网络动态和社区影响，例如

谣言的传播、病毒的爆发和肿瘤的演变等。可以说，社区检测技术让我们在面对各种实际问题时更加的便捷。

1.2 社区检测的发展历程

早在 20 世纪 20 年代，社区的概念就一直是社会学和社会心理学的研究问题；到了 20 世纪 70 年代，传统社区检测方法就开始发展了，直到了 21 世纪，才开发出先进的科学工具，根据现实世界数据来发现社区。近年来，Girvan 和 Newman 通过图形分区的方法，开辟了社区检测的新方向。由于随机网络并不具有社区结构，随着模块度概念的提出，使得网络社区划分的优劣可以有一个明确的评价指标来衡量，社区检测也在此之后得到了快速的发展。在过去的十年里，计算机科学研究人员已经通过使用网络拓扑结构和网络属性对静态和动态网络、小型和大型网络广泛开展了社区检测。此外，还出现了越来越多的基于图形的方法来检测具有复杂数据结构的环境中的社区。目前基于深度学习的社区检测方式已经取代了传统检测方式的主导地位。

1.3 社区检测为什么要进行深度学习

1.3.1 网络规模的膨胀

在大数据的快速发展趋势下，现实生活中的数据量越来越大，网络规模不断扩大，网络尺度和维度极具膨胀，并且在现实世界的网络通常富含非线性信息、复杂的拓扑和高维特征。

1.3.2 传统检测方法的劣势

传统的社区检测方法主要利用网络结构来探索社区，可以简单理解为他们是以直截了当的方式连接节点，从中捕获信息并进行社区划分。由于现实世界的网络通常富含非线性信息，并且通常包括复杂的拓扑和高维特征，很难将网络进行可视化，因此并不能适应大部分的实际需求。许多传统技术，如光谱聚类、和统计推理，通常只能应用于小型网络和简单案例的社区检测。

在传统方式进行社区检测的过程中一般也会将每一个节点都看作相同的地位。然而，经过研究发现，在实际问题中网络的节点也满足“二八规则”，即与大部分节点相比，有一小部分节点在社区中起决定性作用，对网络拓扑结构的演化和网络信息的传播等有着重大影响，比如社交网络中的群主，或领袖等。因此传统的社区检测方式还会产生次优的社区划分结果。

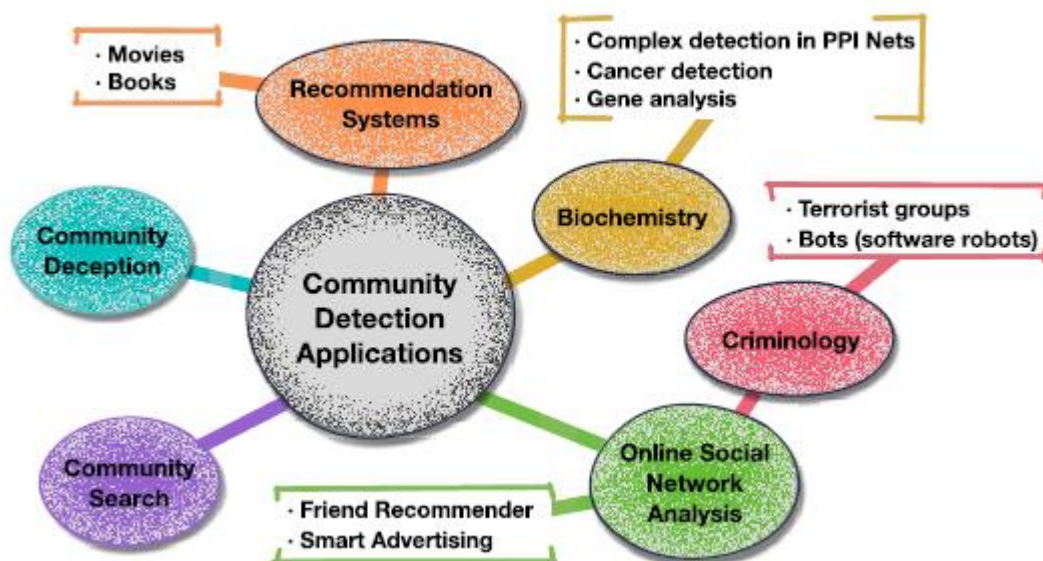
1.3.3 基于深度学习进行社区检测的优势

深度学习模型以网络拓扑和网络属性为输入。由节点和边缘形成的拓扑可以用矩阵表示，如邻接矩阵 A 等；网络属性表示有关网络实体的其他信息，例如节点属性 X 等。

深度学习技术通过最先进的机器学习和数据挖掘技术，可以揭露高维网络信息，并对高维数据到低维矢量的复杂关系进行建模，通过嵌入非结构特征，如节点属性等，增加对社区成员的了解。我们利用深度学习处理大数据的过程中可以更好的探索并显示现实网络场景中的社区结构，如大规模、复杂结构和动态网络。因此通过深度学习，可以得到更加准确的社区检测结果。

1.4 社区检测的应用现状

在当今的网络迅速发展之际，从判断节点所在的社区成为了一项尤为重要工作。而事实上，这一技术也早已渗透到了我们生活中的方方面面，无论是我们平时在用的社交网站、地图还是生物医药方面，都存在社区检测技术。如图二，展示了该文献例举的社区检测五大应用领域：社区搜索，推荐系统，生物化学领域，在线社交网络，社区欺骗。

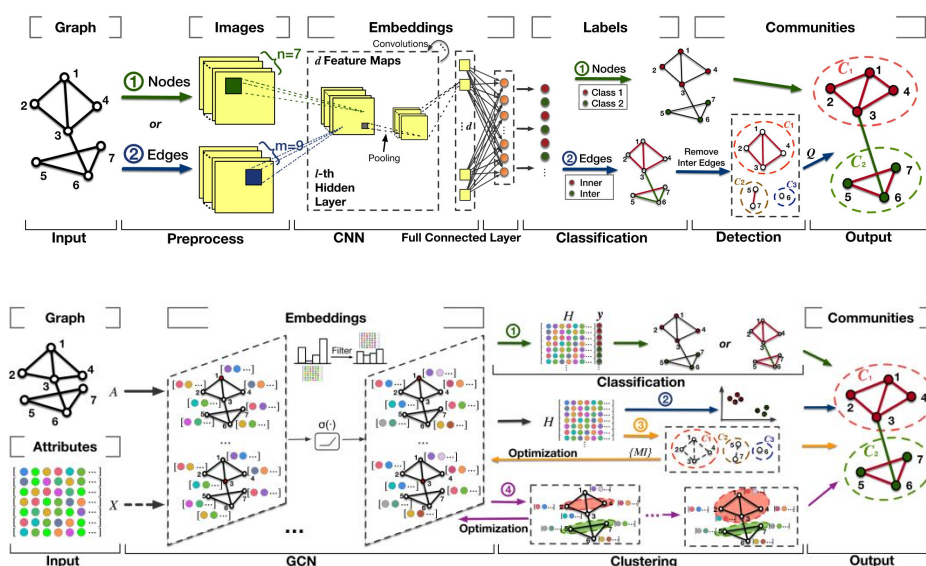


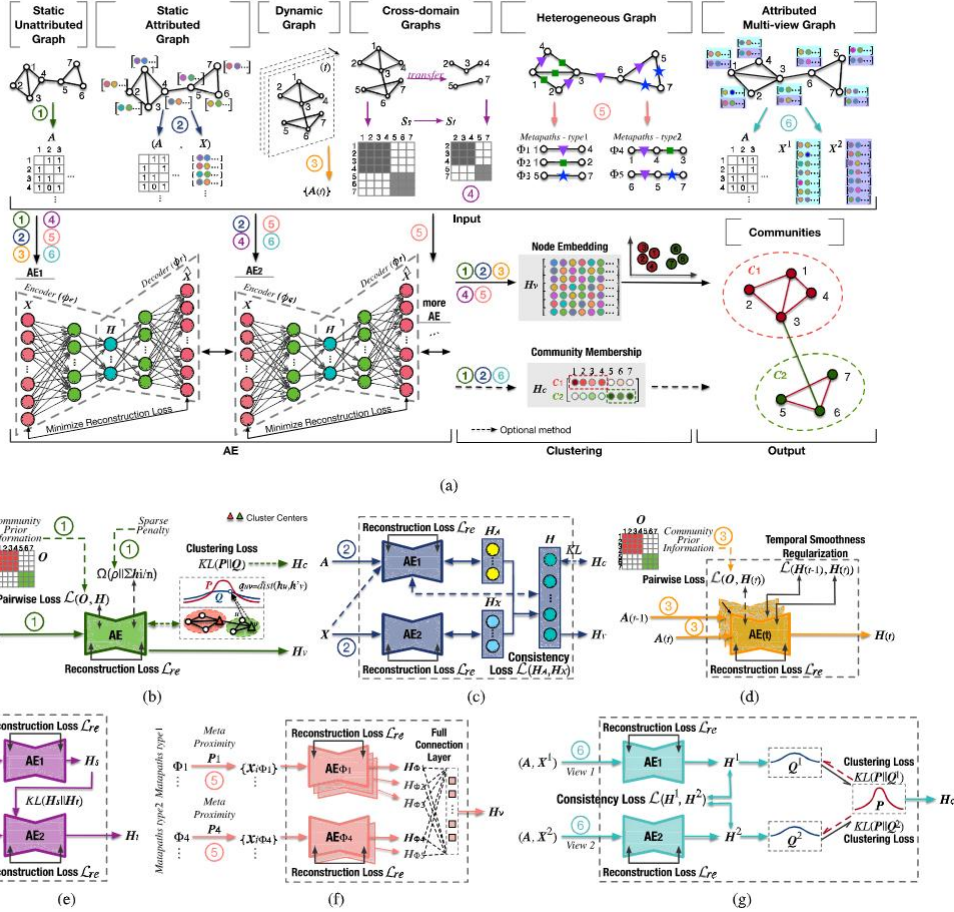
图二：社区检测五大应用领域

随着网络的膨胀和多元化，社区检测也变得更为困难。因此，社区检测领域也需要很快地进行更新迭代，不断改进现有的方法以及推出新方法，这样才能达到与时俱进的目的。

2. 深度学习处理社区检测问题

本文的第二个部分介绍了六种基于深度学习的方法来处理社区检测问题。卷积网络、图注意力网络（GAT）、生成对抗网络（GAN）、自动编码器（AE）、深度非负矩阵分解（DNMF）和深度稀疏滤波（DSF）。其中，卷积网络包括卷积神经网络（CNN）和图卷积网络（GCN）。文章中提到这两者都有助于卷积来表示社区检测的潜在特征。自动编码器（AE）框架中又包含了六类，包括基于堆叠 AE 的社区检测、基于稀疏 AE 的社区检测、基于 AE 的社区检测去噪、基于图卷积 AE 的社区检测、基于图注意力 AE 的社区检测和基于变化 AE（VAE）的社区检测。下面几张图是 CNN、GCN、GAT 等方法来处理社区检测的过程，从这几张图中可以看到最终得到的结果还是非常可信的，这也证明了深度学习具有良好的社区检测性，以及强大的深度学习技术能很好地解决社区检测问题。





由于研讨时间有限，我们组深知要详细地了解以及生动地展示给老师和同学们是非常不易的，因此我们组在课堂上研讨时也就只介绍 CNN 和 AE 这两种处理社区检测的深度学习方法。同样，因为课程报告篇幅有限，我们还是在报告中详细介绍 CNN 和 AE 处理社区检测的过程。其实在课上进行研讨的时候，由于紧张以及时间的原因，我们组感觉有一些东西没有能充分展示出来。所以，我们也将在此报告中详细地展开。

2.1 基于 CNN 卷积神经网络处理社区检测问题

2.1.1 CNN 卷积神经网络算法步骤

先介绍一下 CNN 卷积神经网络如何来处理社区检测问题。在课上的研讨中，我们组在介绍 CNN 的时候尽可能地用简单易懂的方式来进行展示，但在课下我们又阅读了很多的资料，发现 CNN 真的很深奥。所以在这篇报告中，我们选择用更加严谨的语言文字来介绍 CNN。

我们现在已经知道 CNN 在很多领域已经取代常规神经网络了。至于原因的话，我们都知道常规神经网络对于大尺寸图像效果不尽人意。在 CIFAR-10 (在查询资料后，我们发现原来这个 CIFAR-10 是一个非常大的一个图像数据库，这些图像包含 10 个大类，所以 CIFAR-10 一个很好地来介绍 CNN 的例子。所以在报告中我们选择以 CIFAR-10 图像数据库来作为例子)，图像的尺寸是 $32 \times 32 \times 3$ (宽高均为 32 像素，红绿蓝 3 个颜色通道)，因此，对应的的常规神经网络的第一个隐层中，每一个单独的全连接神经元就有 $32 \times 32 \times 3 = 3072$ 个权重。这个数量看起来还可以接受，但是很显然对于线性的全连接结构不适用于更大尺寸的图像。举例说来，一个尺寸为 $200 \times 200 \times 3$ 的图像，会让神经元包含 $200 \times 200 \times 3 = 120000$ 个权重值。而网络中肯定不止一个神经元，那么参数的量就会快速增加！显而易见，这种全连接方式效率低下，大量的参数也很快会导致网络过拟合。

神经元是三维排列的。卷积神经网络针对输入全部是图像的情况，将结构调整得更加合理。与常规神经网络不同，卷积神经网络的各层中的神经元是 3 维排列的：宽度、高度和深度（这里的深度指的是激活数据体的第三个维度，而不是整个网络的深度，整个网络的深度指的是网络的层数）。

举个例子，CIFAR-10 中的图像是作为卷积神经网络的输入，该数据体的维度是 $32*32*3$ （宽度，高度和深度）。我们将看到，层中的神经元将只与前一层中的一小块区域连接，而不是采取全连接方式。对于用来分类 CIFAR-10 中的图像的卷积网络，其最后的输出层的维度是 $1*1*10$ ，因为在卷积神经网络结构的最后部分将会把全尺寸的图像压缩为包含分类评分的一个向量，向量是在深度方向排列的。

一个简单的卷积神经网络是由各种层按照顺序排列组成，网络中的每个层使用一个可以微分的函数将激活数据从一个层传递到另一个层。卷积神经网络主要由三种类型的层构成：卷积层，池化层和全连接层。通过将这些层叠加起来，就可以构建一个完整的卷积神经网络。

2.1. 2CNN 卷积神经网络基本结构


一个用于 CIFAR-10 图像数据分类的卷积神经网络的结构可以是[输入层-卷积层-ReLU 层-汇聚层-全连接层]。过程如下：

- 输入 $[32*32*3]$ 存有图像的原始像素值，本例中图像宽高均为 32，有 3 个颜色通道。
- 卷积层中，神经元与输入层中的一个局部区域相连，每个神经元都计算自己与输入层相连的小区域与自己权重的内积。卷积层会计算所有神经元的输出。如果我们使用 12 个滤波器（也叫作核），得到的输出数据体的维度就是 $[32*32*12]$ 。
- ReLU 层将会逐个元素地进行激活函数操作，比如使用以 0 为阈值的 $\max(0, x)$ 作为激活函数。该层对数据尺寸没有改变，还是 $[32*32*12]$ 。
- 汇聚层在在空间维度（宽度和高度）上进行降采样操作，数据尺寸变为 $[16*16*12]$ 。
- 全连接层将会计算分类评分，数据尺寸变为 $[1*1*10]$ ，其中 10 个数字对应的就是 CIFAR-10 中 10 个类别的分类评分值。

综上，卷积神经网络一层一层地将图像从原始像素值变换成最终的分类评分值。具体说来，卷积层和全连接层对输入执行变换操作的时候，不仅会用到激活函数，还会用到很多参数（神经元的突触权值和偏差）。而 ReLU 层和池化层则是进行一个固定不变的函数操作。卷积层和全连接层中的参数会随着梯度下降被训练，这样卷积神经网络计算出的分类评分就能和训练集中的每个图像的标签吻合了。

2.1. 3CNN 卷积神经网络处理社区检测问题

以上便是 CNN 的大致介绍。我们论文中的这张图：



我们可以看到将一个图（这个图指的肯定是网络图形学中的图），经过预处理分别将节点和边分别变成对应数目的二维矩阵（这个二维矩阵是我方便理解的称呼）。这个预处理我也查了很多的资料，也不是特别的理解，我猜测这个预处理应该算上了图之外的信息，反正我感觉它这个过程是相当复杂的一个过程。经过预处理之后就进入了 CNN 卷积神经网络层，我们可以看到图中是分成了两个 CNN，一个是针对于点的，另一个是针对于边的。经过卷积神经网络的最后一层全连接层之后，就将节点和边分好了类。如图所示，对于 CNN 之后的节点来说，红色的边代表着一类，绿色的节点代表着另外一类的结点，由于全连接层处理之后得到的是两类，所以只有两种颜色的点。对于边来说，全连接层算法计算的结果是将边分为两类，一类是社区内部的边，另一类是社区外面的边，图中用红石代表社区内部的边，绿色代表社区外面的边。另外，我们可以看到图中将分好类的边取出内部的边之后，将原图分成了三个社区。而点的全连接层是将原来的图分成了两个社区。最后将两个结

果合并处理得到一个输出结果。我们可以看到最后合并的这个结果是和我们人为进行划分的结果是一样的，这也证明了 CNN 处理社区检测具有很好的作用。

论文中列举了两个 CNN 处理社区检测的模型。较详细地介绍了第一个基于监督 CNN 的拓扑不完全网络 (TIN) 社区检测模型。模型包含两个 CNN 层，其中最大池操作符用于网络表示，以及一个完全连接的 DNN 层用于社区检测。CNN 架构逐渐从基本输入中恢复完整的潜在特征。论文中也介绍了处理大规模网络中的高稀疏性模型，这点是非常有必要的，因为无论是生活中还是科学研究中都会遇到高稀疏性的模型，所以这个模型的出现是非常必要的。

2.2 基于自动编码器处理社区检测问题

2.2.1 自动编码器的定义

暂且不谈神经网络、深度学习等，仅是自编码器的话，其原理其实很简单。自编码器可以理解为一个试图去还原其原始输入的系统，即可以表示为 Input—Code—Output。自编码器模型主要由编码器 (Encoder) 和解码器 (Decoder) 组成，其主要目的是将输入 x 转换成中间变量 y ，然后再将 y 转换成 x' ，然后对比输入 x 和输出 x' ，使得他们两个无限接近。

在深度学习中，自动编码器是一种无监督的神经网络模型，它可以学习到输入数据的隐含特征，这称为编码 (coding)，同时用学习到的新特征可以重构出原始输入数据，称之为解码 (decoding)。从直观上来看，自动编码器可以用于特征降维，类似主成分分析 PCA，但是其相比 PCA 其性能更强，这是由于神经网络模型可以提取更有效的新特征。除了进行特征降维，自动编码器学习到的新特征可以送入有监督学习模型中，所以自动编码器可以起到特征提取器的作用。举个例子，我有一张清晰图片，首先我通过编码器压缩这张图片的大小（如果展现出来可能比较模糊），然后在需要解码的时候将其还原成清晰的图片。

2.2.2 自动编码器的价值

对已有的目标对象进行简化再重新得到相似的目标对象，看起来是没有价值的操作，但这样做的主要原因是：有时神经网络要接受大量的输入信息，比如输入信息是高清图片时，输入信息量可能达到上千万，让神经网络直接从上千万个信息源中学习是一件很吃力的工作。所以，我们为何不压缩一下，提取出原图片中的最具代表性的信息，缩减输入信息量，再把缩减过后的信息放进神经网络学习。这样学习起来就简单轻松了。所以，自编码就能在这时发挥作用。通过将原数据 x 压缩，解压成 x' ，然后通过对比 x 与 x' ，求出预测误差，利用误差损失函数，进行反向传递，逐步提升自编码的准确性。训练好的自编码中间这一部分就是能总结原数据的精髓。可以看出，从头到尾，我们只用到了输入数据 x ，并没有用到 x 对应的数据标签，所以也可以说自编码是一种非监督学习。到了真正使用自编码的时候，通常只会用到自编码前半部分。这样一种自编码的深度学习算法就可以应用在我们的社区检测中，进行社区识别。

2.2.3 AES 算法及其结构

AES (Advanced Encryption Standard) 算法常用于无监督的社区检测。

AES 可以描述出非线性的、有噪声的真实网络，并通过重建表示丰富信息的社区。用于 AES 的一般框架包括编码器和解码器。编码器映射高维网络结构和可能的属性到低维潜在特征空间。

AES 算法基本结构分为字节代换，行移位，列混合，轮密钥加。

首先进行密钥扩展，然后把 128 位长度的字符串读进一个 4×4 的整数数组中。

即为进行字节代换，就是把状态矩阵中的每个元素传进 `getNumFromSBox()` 函数中，然后取得前面 8 位中的高 4 位作为行值，低 4 位作为列值，得到状态矩阵。

行移位的时候，首先把状态矩阵中第 2, 3, 4 行复制出来，然后对它们行进左移相应的位数，然后再复制回去状态矩阵 array 中。列混合变换是通过矩阵相乘来实现的，经行移位后的状态矩阵与固定的矩阵相乘，得到混淆后的状态矩阵。轮密钥加是将 128 位轮密钥同状态矩阵中的数据进行逐位异或操作。

以上是对数据的加密操作，完成之后上述操作的逆运算即为对代码的解密运算。

2.2.4 AES 算法的优化与创新

基于堆叠的 AES 社区检测。与单个 AES 相比，在深度隐藏层中开发的堆叠 AES 通过将每个层的输出与连续层的输入连接起来，可以更好地嵌入高维社区特征。在这种体系结构中，堆叠的 AES 代表了多层次的动态信息，以灵活地支持广泛的社区检测实现。基于 DNN 的半监督非线性重构算法是一种堆叠 AES 的设计，其中模块化矩阵学习 AES 中的非线性节点表示，并使用 k-means 集群最终的社区结构。

基于去噪的 AES 社区检测。去噪过程，即去除 DNN 层内的噪声，可以提高模型的鲁棒性（指控制系统在一定（结构，大小）的参数摄动下，维持其它某些性能的特性）。在这种情况下，去噪 AES 通过最小化 L 损失函数来最小化输入 x 和输出 x' 的解码特征之间的重构损失。

基于图注意力（GAT）的 AES 社区检测。将 GAT 与 AES 集成，其中 GAT 作为编码器，对邻域内节点的重要性进行排序。例如，深度注意嵌入式图聚类（DAEGC）在自我训练过程中利用具有图注意的 AES 中的高阶邻居。除此之外，具有聚类特异性分布的图嵌入聚类（GEC-CSD）使用一个同样配备了图注意力的 AES 作为生成器，以学习对抗性学习框架内的社区表示，该框架也集成了自我训练。在这里，鉴别器确保了在聚类分布中存在多样性。另外，还有在网络中的多视图属性方面，多视图属性图卷积网络（MAGCN）涉及到一个双路径编码器。第一个路径用 GAT 编码多视图属性，以减少噪声。第二个路径是学习多视图属性上的一致嵌入。因此，噪声和分布的方差被去除。在这种情况下，还有自监督图卷积。

用于图表示的深度神经网络（DNNGR）应用堆叠去噪编码器来提高捕获局部结构信息时的鲁棒性。具体地说，它通过在社区上随机行走，生成一个概率共现矩阵和一个移位的正点互信息矩阵（衡量两个事务的相关性）。作为对 DNNGR 的扩展，基于深度神经网络的面向聚类的网络嵌入联合学习节点嵌入和聚类分配。为了处理稀疏和有噪声的节点属性，具有动态嵌入的图聚类利用去噪 AES 学习鲁棒节点嵌入，然后在社区内传播，以捕获自训练聚类过程中动态变化的社区间活动。

2.3 算法总结概况

我们介绍了 CCN, AES 深度学习算法，了解了其算法结构和原理。其实也包括 NMF 非负矩阵分解算法（将高位矩阵转化为低维矩阵）。我们会发现这些算法的核心都可以归结为“化繁为简”，也就是将高维复杂的指标描述转化为低维简洁的指标，以来方便我们进行提取描述。与此同时，深度学习下这些算法中都有误差损失函数去不断优化，不断优化我们结果，比如去缩小自动编码器中 x 与 x' 的误差。这种算法的核心思想值得我们学习。

3. 社区检测的应用及发展方向

社区检测在不同的任务和领域上有许多应用程序，如社区欺骗、社区搜索、生物化学等领域。

虽然深度学习已经将社区检测带入了一个繁荣的时代，但仍有几个有待解决的问题有待进一步研究。它们分别是未知社区数量、社区嵌入、分层网络、多层网络、异构网络、网络异质性、拓扑不完全网络、跨域网络、属性化多视图网络、标签网络、动态网络、大规模网络。在这些领域我们可能会在使用深度学习算法时遇到很多问题，但同样也需要利用深度学习来解决这些问题的机会。

过去的十年里，许多基于深度学习模型的显著方法已经被开发出来，这些方法显著提高了社区检测的有效性、效率、鲁棒性和适用性。新技术比传统方法更灵活，在预处理过程中可以利用更多的数据。因此，我们有选择地将所回顾的方法总结为六个新的类别。依次讨论迄今为止每个类别的发展以及每个方向的贡献。

参考文献（格式）

- [1] 王竹溪, 郭敦仁, 特殊函数概论, 北京, 科学出版社, 1979: 381-417
- [2] 赵耀, 基于小波变换的抵抗几何攻击的鲁棒视频水印, 中国科学 E 辑, **36**(2), 2006: 137-152
- [3] Pan X, *et al.*, Data Redundancy and Reduced-Scan Reconstruction in Reflectivity Tomography, *IEEE Trans. Image Processing*, 2003, **12**(7): 784-795
- [4] Slinger C, Cameron C, and Stanley M, Computer Generated Holography as a Generic Display Technology, *IEEE Computer*, **38**(8), 2005: 46-53
- [5] Ground Truth Database, <http://www.cs.washington.edu/research/imagetatabase/groundtruth/>
- [6] Kamon K, and Matsuda S, Image Reading Apparatus for Reading Book-Like Documents, US Patent. No. 6041146, March 2000